

Segmentação isotônica e temporal por programação dinâmica

Versão revisada e ponderada de

`isotonic_temporal_binning_dp`

Metodologia para construir grupos homogêneos contíguos sobre o score, combinando ordenação de risco, suavização temporal, estabilidade populacional, separação entre grupos e seleção parcimoniosa da granularidade.

Sumário

1. Objetivo	4
2. Entradas esperadas	4
3. Papel dos pesos	5
4. Etapa 1 - Pré-binning por quantis ponderados	6
5. Etapa 2 - Matriz ponderada de taxas por pré-bin e período	6
6. Etapa 3 - Suavização isotônica e temporal	7
1. 6.1 Problema de otimização	7
2. 6.2 Normalização dos pesos	7
3. 6.3 Tendência monotônica	7
4. 6.4 Resolução por ADMM	7
7. Etapa 4 - Estatísticas de cada segmento candidato	8
1. 7.1 Taxa mensal do segmento	8
2. 7.2 Custo de perda de informação	8
3. 7.3 Estabilidade populacional por PSI	9
4. 7.4 Restrições de suporte	9
8. Etapa 5 - Separação e não inversão entre grupos adjacentes	9
1. 8.1 Não inversão	10
2. 8.2 Penalização de separação insuficiente	10
9. Etapa 6 - Função objetivo para uma partição	10
10. Etapa 7 - Programação dinâmica corrigida	11
1. 10.1 Por que o estado simples é insuficiente	11
2. 10.2 Estado revisado	11
3. 10.3 Garantia de optimalidade	12
4. 10.4 Complexidade computacional	12
11. Escolha do número de grupos	12

12. Principais parâmetros	13
1. n_prebins	13
2. lambda_time	13
3. psi_strength	13
4. separation_strength	13
5. min_rate_diff	13
6. complexity_strength	13
7. min_group_weight_share	13
8. min_monthly_group_weight_share	14
9. objective_tolerance	14
13. Estrutura da saída	14
1. cutpoints	14
2. best_solution	14
3. suggestions	14
4. solutions	14
5. prebin_table	15
6. observed_rates	15
7. smoothed_rates	15
8. population_weights	15
9. weighted_events	15
10. smoothing_diagnostics	15
11. configuration	15
14. Exemplo de uso	16
15. Diagnósticos recomendados antes da adoção	16
16. Limitações e decisões metodológicas	17
1. Pré-binning condiciona os cortes possíveis	17
2. Períodos são tratados como igualmente espaçados	17
3. A suavização e a segmentação não são otimizadas conjuntamente	17
4. PSI mede estabilidade de participação, não estabilidade completa	17
5. Pesos extremos reduzem n_{eff}	17
6. A direção automática é apenas uma heurística	17
17. Correções incorporadas nesta versão	18

1. Objetivo

A metodologia constrói grupos homogêneos contíguos sobre o score de um modelo, procurando conciliar cinco propriedades:

- 1. ordenação de risco:** grupos de score sucessivos devem apresentar taxas de evento monotônicas;
- 2. consistência temporal:** a estrutura de risco não deve reagir excessivamente a ruído mensal;
- 3. estabilidade populacional:** a participação de cada grupo deve variar pouco entre os períodos;
- 4. separação de risco:** grupos adjacentes devem representar níveis de risco materialmente distintos;
- 5. parcimônia:** a quantidade de grupos deve ser suficiente para preservar informação, mas não tão grande que produza fragmentação e instabilidade.

A versão ponderada considera um peso amostral ou de expansão populacional em todas as etapas relevantes. Assim, os cortes são definidos para representar a população modelada, e não apenas a distribuição bruta da amostra de desenvolvimento.

A solução é composta por duas otimizações encadeadas:

- uma etapa convexa de suavização isotônica e temporal das taxas por pré-bin e período;
- uma etapa discreta de programação dinâmica que agrega os pré-bins em grupos finais.

A programação dinâmica revisada mantém o último segmento completo em seu estado. Isso permite incorporar corretamente o custo de separação entre grupos adjacentes e alcançar o mínimo global da função discreta definida, condicionada aos pré-bins e à superfície suavizada.

2. Entradas esperadas

Cada linha representa uma observação individual e contém, no mínimo:

- **score:** valor numérico utilizado para ordenar os indivíduos;
- **month:** referência temporal;
- **target:** indicador de evento, normalmente binário;
- **weight:** peso amostral ou fator de expansão populacional, opcional.

Quando `weight_col=None`, cada linha recebe peso igual a 1.

O peso deve ser finito e não negativo. Observações com peso zero não influenciam a estimação.

A variável alvo pode ser binária ou assumir valores fracionários entre 0 e 1, embora o uso habitual seja um target binário.

3. Papel dos pesos

Seja w_i o peso da observação i . Na versão ponderada, ele é tratado como massa populacional.

Os pesos são empregados em:

- criação dos quantis ponderados;
- volume de cada pré-bin e período;
- cálculo das taxas de evento;
- intensidade estatística das células na suavização;
- restrições mínimas de tamanho;
- cálculo da estabilidade populacional por PSI;
- custo de perda de informação ao consolidar pré-bins;
- cálculo das taxas observadas e suavizadas dos grupos finais.

A taxa de evento da célula formada pelo pré-bin b e pelo período t é:

$$r_{bt} = E_{bt} / N_{bt}$$

em que:

- $N_{bt} = \sum_{i \in (b,t)} w_i$ é o volume populacional ponderado;
- $E_{bt} = \sum_{i \in (b,t)} w_i y_i$ é o volume ponderado de eventos.

A soma dos pesos não é usada diretamente como quantidade de observações independentes na penalização de complexidade. Para essa finalidade, utiliza-se o tamanho amostral efetivo de Kish:

$$n_{eff} = (\sum_i w_i)^2 / \sum_i w_i^2$$

Isso evita que fatores de expansão muito elevados façam a amostra parecer estatisticamente maior do que realmente é.

4. Etapa 1 - Pré-binning por quantis ponderados

O espaço do score é inicialmente dividido em B pré-bins contíguos.

Os pontos de corte preliminares são quantis da distribuição ponderada do score. Dessa forma, cada pré-bin busca representar uma parcela semelhante da população expandida, não necessariamente uma quantidade semelhante de linhas da amostra.

O pré-binning cumpre três funções:

- reduz drasticamente o espaço combinatório de cortes;
- preserva a ordenação natural do score;
- permite que a otimização posterior trabalhe sobre estatísticas agregadas.

Empates no score podem fazer com que a quantidade real de pré-bins seja menor que $n_{\text{pre-bins}}$. A implementação remove fronteiras duplicadas e comprime pré-bins vazios sem alterar a ordem do score.

A discretização utiliza intervalos fechados à direita. Portanto, um ponto de corte c produz a regra:

- grupo inferior: $\text{score} \leq c$;
- grupo seguinte: $\text{score} > c$.

5. Etapa 2 - Matriz ponderada de taxas por pré-bin e período

Após o pré-binning, são construídas três matrizes $B \times T$:

- N : pesos populacionais $N_{\beta t}$;
- E : eventos ponderados $E_{\beta t}$;
- R : taxas observadas $r_{\beta t}$.

Células sem observações possuem peso zero. Sua taxa não é estimada diretamente pelos dados; ela é inferida na etapa de suavização a partir das estruturas temporal e monotônica.

6. Etapa 3 - Suavização isotônica e temporal

6.1 Problema de otimização

A superfície suavizada $\Theta = \{\theta_{\beta t}\}$ é obtida resolvendo:

$$\min_{\Theta} \frac{1}{2} \sum_{\beta, t} \hat{w}_{\beta t} (r_{\beta t} - \theta_{\beta t})^2 + \lambda_{\text{tempo}} / 2 \sum_{\beta, t(t>1)} (\theta_{\beta t} - \theta_{\beta, t-1})^2$$

sujeito a, para todo período t:

$$\theta_{1t} \leq \theta_{2t} \leq \dots \leq \theta_{B_t}$$

quando o risco é crescente com o score, ou à desigualdade inversa quando o risco é decrescente.

A primeira parcela preserva aderência às taxas observadas. A segunda penaliza alterações abruptas entre períodos consecutivos.

6.2 Normalização dos pesos

Os pesos das células são divididos pela média dos pesos positivos antes da suavização. Essa normalização não muda a importância relativa das células, mas impede que a interpretação de `lambda_time` dependa da escala arbitrária do fator de expansão populacional.

6.3 Tendência monotônica

A direção pode ser definida explicitamente:

- `increasing`: maior score implica maior taxa de evento;
- `decreasing`: maior score implica menor taxa de evento.

Em `auto`, a implementação utiliza o sinal da correlação ponderada entre score e target.

Em aplicações reguladas, recomenda-se definir a direção explicitamente quando a semântica do score já é conhecida.

6.4 Resolução por ADMM

O problema combina uma função quadrática suave com uma restrição isotônica. Ele é resolvido por ADMM, alternando:

1. uma atualização temporal quadrática para cada pré-bin;
2. uma projeção isotônica por período usando PAVA;

3. a atualização da variável dual.

A atualização temporal resolve um sistema linear tridiagonal equivalente à penalização das primeiras diferenças ao longo do tempo.

A projeção isotônica é exata para a norma euclidiana e é executada pelo algoritmo Pool Adjacent Violators, PAVA.

A convergência é monitorada pelos resíduos primal e dual. Os diagnósticos são devolvidos em `smoothing_diagnostics`.

7. Etapa 4 - Estatísticas de cada segmento candidato

Um grupo final candidato corresponde a um intervalo contíguo de pré-bins $[a,b]$.

Para cada segmento são calculados:

- volume ponderado total;
- participação populacional total;
- participação em cada período;
- taxa suavizada em cada período;
- perda de informação ao consolidar os pré-bins;
- contribuição aditiva ao PSI;
- validade das restrições mínimas de suporte.

7.1 Taxa mensal do segmento

Para o segmento $g = [a,b]$, a taxa suavizada no período t é:

$$\mu_{gt} = \sum_{j=a}^b N_{jt} \theta_{jt} / \sum_{j=a}^b N_{jt}$$

7.2 Custo de perda de informação

Ao reunir diferentes pré-bins no mesmo grupo, cada taxa θ_{jt} é substituída por μ_{gt} . A perda resultante é:

$$C_{/it}(g) = [\sum_{j \in g} N_{jt} (\theta_{jt} - \mu_{gt})^2] / \sum_{j \in g} N_{jt}$$

Esse custo está em unidades de taxa ao quadrado e mede a heterogeneidade de risco descartada pela agregação.

7.3 Estabilidade populacional por PSI

A participação do segmento g no período t é:

$$pg_t = Ng_t / N_t$$

A referência é sua participação ponderada no horizonte completo:

$$pg = Ng / N$$

A contribuição do grupo ao PSI é:

$$C^{PSI}(g) = \sum_t \omega_t (pg_t - pg) \ln(pg_t / pg)$$

$$\text{em que } \omega_t = N_t / \sum_s N_s.$$

Como o PSI total é a soma das contribuições dos grupos, esse termo é aditivo e pode ser incluído diretamente na programação dinâmica.

7.4 Restrições de suporte

Um segmento só é elegível quando satisfaz simultaneamente:

- participação ponderada total $\geq \text{min_group_weight_share}$;
- participação ponderada em cada período $\geq \text{min_monthly_group_weight_share}$;
- peso positivo em todos os períodos.

Essas são restrições duras, não penalizações. Um segmento inválido recebe custo infinito e nunca é escolhido.

8. Etapa 5 - Separação e não inversão entre grupos adjacentes

Para dois grupos consecutivos g_- e g_+ , define-se, em cada período, o gap orientado:

$$\Delta_t = \mu_{g_+,t} - \mu_{g_-,t}$$

para tendência crescente, ou o sinal inverso para tendência decrescente.

8.1 Não inversão

Qualquer transição com $\Delta_t < -\varepsilon$ em algum período é considerada inviável.

Embora a superfície isotônica já torne a inversão improvável, a restrição é verificada explicitamente na etapa discreta.

8.2 Penalização de separação insuficiente

A separação desejada é `min_rate_diff`. O custo de transição é:

$$T(g_-, g_+) = \sum_t \omega_t [\max(0, \delta_{\min} - \Delta_t)]^2$$

Esse custo é zero quando o gap entre os grupos atende ao mínimo desejado em todos os períodos.

A penalização é multiplicada por `separation_strength`.

Diferentemente de uma correção pós-processamento, esse custo participa da escolha dos cortes. Portanto, a programação dinâmica pode preferir fronteiras diferentes para melhorar a separação sem destruir a solução posteriormente por merges gulosos.

9. Etapa 6 - Função objetivo para uma partição

Para uma partição $\mathcal{P}$ com K grupos, a função objetivo é:

$$\begin{aligned} J(\mathcal{P}, K) = & \sum_{g \in \mathcal{P}} C_{fit}(g) \\ & + \lambda^{PSI} \sum_{g \in \mathcal{P}} C^{PSI}(g) \\ & + \lambda_{sep} \sum_{g_-, g_+} T(g_-, g_+) \\ & + C_{comp}(K) \end{aligned}$$

A escala do termo de PSI é definida por:

$$\lambda^{PSI} = \text{psi_strength} \times \text{Var}^w(Y)$$

Isso converte o PSI, que é adimensional, para uma escala comparável à perda em taxa ao quadrado.

A penalização de complexidade é:

$$C_{\text{comp}}(K) = \text{complexity_strength} \times \text{Var}^w(Y) \times [\ln(n_{e/f})/n_{e/f}] \times K$$

Ela é inspirada na lógica de critérios de informação: grupos adicionais são aceitos apenas quando reduzem suficientemente os demais custos.

10. Etapa 7 - Programação dinâmica corrigida

10.1 Por que o estado simples é insuficiente

Uma formulação do tipo $D[k,b]$, que guarda apenas o melhor custo para dividir os pré-bins até b em k grupos, é suficiente quando o custo total é exclusivamente a soma de custos individuais dos segmentos.

Ela deixa de ser suficiente quando existe um custo entre grupos adjacentes. Duas soluções que terminam no mesmo b podem possuir últimos grupos diferentes e, conseqüentemente, custos de transição diferentes com o próximo grupo.

Descartar essa informação pode eliminar um caminho que não é o melhor naquele ponto, mas que levaria ao melhor resultado global depois da próxima transição.

10.2 Estado revisado

A implementação utiliza:

$$F[k,a,b]$$

como o menor custo para particionar os pré-bins de 0 até b em k grupos, sabendo que o último grupo é exatamente $[a,b]$.

A recorrência é:

$$F[k,a,b] = C(a,b) + \min_h \{F[k-1,h,a-1] + T([h,a-1],[a,b])\}$$

em que $C(a,b)$ inclui o custo de fit e o custo de PSI do segmento.

O predecessor h é armazenado para reconstruir os cortes ótimos.

10.3 Garantia de optimalidade

Para cada K fixo, essa recorrência encontra o mínimo global da função discreta definida, desde que:

- os cortes sejam restritos às fronteiras dos pré-bins;
- a superfície suavizada esteja fixa;
- o custo dependa apenas de cada segmento e da transição entre segmentos adjacentes;
- as restrições estejam corretamente representadas como validade de segmentos ou transições.

A garantia não significa mínimo global conjunto sobre todos os cortes contínuos possíveis e sobre a própria superfície isotônica. Trata-se do mínimo global da etapa de segmentação condicionada ao pré-binning e à suavização já calculada.

10.4 Complexidade computacional

A etapa de pré-cálculo dos segmentos é aproximadamente $O(B^2T)$.

O pré-cálculo das transições é aproximadamente $O(B^3T)$.

A programação dinâmica é aproximadamente $O(KB^3)$.

Com 30 a 60 pré-bins, essa complexidade costuma ser administrável. Valores muito elevados de `n_prebins` podem aumentar materialmente tempo e memória.

11. Escolha do número de grupos

A função resolve separadamente todos os valores inteiros entre `min_groups` e `max_groups`.

Depois de acrescentar a penalização de complexidade, as soluções são comparadas pela função objetivo completa.

A saída `suggestions` busca fornecer até três alternativas:

- 1. melhor objetivo:** menor função objetivo total;
- 2. mais parcimoniosa:** menor número de grupos dentro da tolerância relativa definida por `objective_tolerance`;
- 3. mais granular:** maior número de grupos dentro da mesma tolerância.

Quando as alternativas parcimoniosa ou granular coincidem com a melhor solução, a função completa a lista com as próximas soluções no ranking.

Esse formato evita tratar a quantidade de grupos como uma decisão puramente matemática. O Data Scientist pode comparar soluções quase equivalentes e incorporar requisitos de implantação, comunicação, política de crédito e monitoramento.

12. Principais parâmetros

n_prebins

Controla a resolução inicial dos cortes. Mais pré-bins oferecem maior flexibilidade, mas elevam o custo cúbico da etapa discreta.

Faixa inicial razoável: 30 a 60.

lambda_time

Controla a suavização temporal.

- valor baixo: maior aderência às oscilações mensais observadas;
- valor alto: trajetória temporal mais regular.

Os pesos das células são normalizados, de modo que esse parâmetro não muda de interpretação apenas porque os pesos foram multiplicados por uma constante.

psi_strength

Controla a importância da estabilidade das participações populacionais.

O multiplicador efetivo é ajustado pela variância ponderada do target.

separation_strength

Controla quanto a solução evita grupos adjacentes com diferenças inferiores a `min_rate_diff`.

min_rate_diff

Gap mínimo desejado entre as taxas de grupos adjacentes em cada período.

É um objetivo suave: diferenças menores são permitidas, mas penalizadas. Inversões são proibidas.

complexity_strength

Controla a penalização por quantidade de grupos. O termo também depende da variância ponderada do target e de n_{eff} .

min_group_weight_share

Participação populacional mínima de cada grupo no horizonte completo.

min_monthly_group_weight_share

Participação populacional mínima de cada grupo em todos os períodos.

Essa restrição costuma ser mais exigente e pode tornar certos valores de K inviáveis.

objective_tolerance

Define quão próxima da melhor solução uma alternativa deve estar para ser classificada como parcimoniosa ou granular.

13. Estrutura da saída

A função retorna um dicionário com:

cutpoints

Tupla com os cortes da solução de melhor objetivo.

best_solution

Objeto `BinningSolution` contendo:

- quantidade de grupos;
- segmentos de pré-bins;
- cortes;
- função objetivo total;
- decomposição dos custos;
- menor participação total;
- menor participação mensal;
- menor gap adjacente;
- resumo geral dos grupos;
- resumo mensal dos grupos.

suggestions

Tabela com até três recomendações de quantidade de grupos.

solutions

Dicionário com todas as soluções viáveis, indexado pelo número de grupos.

prebin_table

Resumo ponderado dos pré-bins.

observed_rates

Matriz de taxas ponderadas observadas por pré-bin e período.

smoothed_rates

Superfície isotônica e temporal utilizada na otimização.

population_weights

Matriz de volumes ponderados.

weighted_events

Matriz de eventos ponderados.

smoothing_diagnostics

Número de iterações, indicador de convergência e resíduos do ADMM.

configuration

Parâmetros derivados, incluindo direção monotônica, variância ponderada do target, n_{eff} e multiplicadores efetivos.

14. Exemplo de uso

```
from isotonic_temporal_binning_dp_weighted import (
    isotonic_temporal_binning_dp,
    apply_isotonic_temporal_binning,
)

result = isotonic_temporal_binning_dp(
    df,
    score_col="score",
    time_col="month",
    target_col="target",
    weight_col="sample_weight",
    n_prebins=40,
    min_groups=4,
    max_groups=10,
    monotonic_trend="increasing",
    lambda_time=2.0,
    psi_strength=0.05,
    separation_strength=1.0,
    min_rate_diff=0.005,
    min_group_weight_share=0.03,
    min_monthly_group_weight_share=0.01,
)

cutpoints = result["cutpoints"]
suggestions = result["suggestions"]
group_summary = result["best_solution"].group_summary
monthly_summary = result["best_solution"].monthly_summary

new_data["risk_group"] = apply_isotonic_temporal_binning(
    new_data["score"],
    cutpoints,
)
```

15. Diagnósticos recomendados antes da adoção

A função produz uma solução matemática, mas sua adoção deve ser acompanhada por validação analítica.

Recomenda-se verificar:

- convergência do ADMM;
- taxas observadas e suavizadas por grupo e período;
- monotonicidade nas taxas observadas, além da superfície suavizada;
- frequência e magnitude de gaps inferiores a `min_rate_diff`;
- PSI das participações dos grupos;
- volume ponderado e quantidade bruta de linhas por grupo;

- estabilidade por subpopulações de negócio;
- capture rate e demais métricas de ordenação;
- comportamento em amostra OOT não utilizada na escolha dos cortes;
- sensibilidade dos resultados a `n_prebins`, `lambda_time` e restrições de suporte.

Em particular, monotonicidade da superfície suavizada não garante que toda taxa bruta mensal esteja ordenada. A taxa observada continua sujeita a variabilidade amostral. A comparação entre `observed_weighted_bad_rate` e `smoothed_bad_rate` ajuda a distinguir ruído de uma deterioração estrutural.

16. Limitações e decisões metodológicas

Pré-binning condiciona os cortes possíveis

A solução final só pode cortar nas fronteiras geradas pelo pré-binning. Aumentar `n_prebins` amplia o espaço de busca, mas também o custo computacional.

Períodos são tratados como igualmente espaçados

A penalização temporal usa diferenças entre referências consecutivas na ordem fornecida. Caso os intervalos temporais sejam irregulares, seria necessário adaptar a matriz de penalização para considerar a distância entre períodos.

A suavização e a segmentação não são otimizadas conjuntamente

A superfície Θ é estimada antes da programação dinâmica. A DP encontra o melhor agrupamento para essa superfície fixa.

PSI mede estabilidade de participação, não estabilidade completa

O PSI não substitui análises de drift de taxa, performance, calibração ou composição de subgrupos.

Pesos extremos reduzem n_{eff}

Pesos muito concentrados podem fazer poucas linhas dominarem a população expandida. Nessa situação, recomenda-se avaliar a origem dos pesos, sua distribuição e eventual truncamento metodologicamente justificado.

A direção automática é apenas uma heurística

A correlação ponderada fornece o sentido geral da associação, mas pode ser inadequada em scores invertidos, relações não lineares ou amostras com drift. Quando possível, a direção deve ser informada explicitamente.

17. Correções incorporadas nesta versão

Esta revisão introduz quatro correções estruturais importantes:

- 1. o custo de separação passou a fazer parte da recorrência da DP**, em vez de ser aplicado apenas após a segmentação;
- 2. o estado da DP preserva o último segmento**, eliminando a compressão inválida que poderia perder a solução global quando há custos de transição;
- 3. a suavização isotônica e temporal é formulada como um problema convexo explícito**, resolvido por ADMM com diagnóstico de convergência;
- 4. os pesos são propagados por todo o processo**, desde os quantis até a avaliação final, enquanto n_{eff} é usado para não superestimar a informação estatística disponível.

O resultado é uma implementação mais coerente entre formulação, objetivo otimizado e propriedades esperadas dos grupos finais.